

Filière : GI 4 ème Année
Module : Intelligence Artificielle
Enseignant : Mouhib Imad ||

Partie Théorique :

Expliquez minutieusement le principe de ces Algorithmes :

KNN – SVM – Régression Logistique – DBScan – K-Means

Expliquez les notions suivantes :

cross_val_score - StandardScaler - stratify=y - random_state=42 - Oversampling - Class weights - Matrice de Confusion – Précision – Recall – Accuracy F1 Score – méthode de coude – méthode de silhouette.

Répondez aux questions suivantes Comment appelle-t-on la Fonction de la Régression logistique, Dessinez là.

1. Dans SVM, expliquez le rôle des vecteurs de support (support vectors).
2. Quelle est la différence entre un SVM linéaire et un SVM non linéaire ?
3. Définissez les notions suivantes dans DBSCAN :
 - ✓ Point cœur (core point),
 - ✓ Point frontière (border point),
 - ✓ Point bruit (noise point).
4. Quelle est la différence entre Algorithme de Classification et de Régression ?

Partie Pratique :

Une entreprise de télécommunication souhaite analyser ses clients afin de :

- Prédire si un client va quitter l'entreprise.
- Segmenter les clients selon leurs comportements.

Le Dataset contient les variables suivantes :

- Âge,
- Revenu,
- Nombre d'appels,
- Durée moyenne des appels,
- Consommation Internet,
- Nombre de réclamations,

- Type d'abonnement,
 - Historique de paiement.
1. L'objectif est de prédire si un client va quitter l'entreprise, puis le segmenter par comportement : Quels Algorithmes choisirez-vous ? Justifiez
 2. Les données contiennent beaucoup de bruit et des valeurs aberrantes. Quel algorithme est le plus robuste : KNN – DBSCAN – Régression Logistique ?
 3. Le Dataset contient 5 millions de clients. Pourquoi KNN peut-il devenir problématique ?
 4. Les données ne sont pas linéairement séparables. Quel type de SVM recommanderiez-vous ?
 5. Selon le tableau ci-après, Pourquoi ce modèle peut-il être mauvais malgré une accuracy élevée ?

```
model = LogisticRegression()
```

Résultat obtenu :

Accuracy	Precision	Recall
95%	40%	35%


6. Le code à gauche permet l'affichage de la matrice de corrélation à droite

```
plt.figure(figsize=(8, 6))
sns.heatmap(X.corr(), annot=True, cmap='coolwarm', center=0)
plt.title('Matrice de corrélation')
plt.show()
```



→ Expliquez l'utilité de cette Matrice tout en mettant en évidence les couleurs et les chiffres existant dans les cellules.

7. En considérant la courbe $WCSS = f(K)$ suivante :



Sachant que la variation relative du WCSS entre K et K+1 (pour k de 1 à 10)

$[\Delta K = (WCSS(K) - WCSS(K+1)) / WCSS(K) \times 100]$ a donné le résultat suivant :

K=1	->	K=2	:	ΔK	=	42.69%
K=2	->	K=3	:	ΔK	=	43.48%
K=3	->	K=4	:	ΔK	=	41.28%
K=4	->	K=5	:	ΔK	=	24.22%
K=5	->	K=6	:	ΔK	=	14.39%
K=6	->	K=7	:	ΔK	=	6.20%
K=7	->	K=8	:	ΔK	=	7.80%
K=8	->	K=9	:	ΔK	=	3.97%
K=9	->	K=10	:	ΔK	=	7.38%

Quel K est meilleur ? Expliquez pourquoi ?